Avaliação de Modelos de Detecção de Objetos para Visão Computacional Assistiva Embarcada

Anonymous Author(s)
Department / Institution
anonymized for double-blind review
anonymized@wvc2026.org

Anonymous Author(s)
Department / Institution
anonymized for double-blind review
anonymized@wvc2026.org

Anonymous Author(s)
Department / Institution
anonymized for double-blind review
anonymized@wvc2026.org

Anonymous Author(s)
Department / Institution
anonymized for double-blind review
anonymized@wvc2026.org

Abstract*—Visual impairment can compromise mobility and safety in dynamic environments, motivating assistive solutions capable of identifying potential obstacles. This study investigates the hypothesis that computer vision models trained with school-specific data can detect potentially hazardous objects under different environmental conditions while maintaining characteristics suitable for embedded applications. A wearable prototype based on Raspberry Pi was developed, and different object detection and semantic segmentation architectures were trained and evaluated using a custom dataset comprising five object classes. YOLO11 and YOLO26 were selected for experimental evaluation in a known environment and an environment not represented during dataset construction. YOLO26 achieved higher mAP@50-95 and confidence levels for specific classes, whereas YOLO11 detected all five classes in the known environment. In the unseen environment, both models detected three classes. The results demonstrate the approach's potential while revealing generalization limitations, indicating the need for greater dataset diversity and further embedded-performance evaluation.

Keywords — Assistive Technology, Object Detection, Embedded Computer Vision, YOLO.

I. INTRODUÇÃO

A deficiência visual pode comprometer a autonomia e a mobilidade dos indivíduos, especialmente em ambientes dinâmicos nos quais obstáculos temporários dificultam a percepção segura do espaço. No contexto escolar, corredores constituem áreas de circulação sujeitas à presença de objetos deslocados, mochilas e mobiliário, que podem aumentar o risco de quedas e colisões. Estudos indicam que fatores ambientais estão associados à ocorrência de acidentes nesses espaços, evidenciando a importância de mecanismos capazes de identificar antecipadamente potenciais riscos [1,2].

Avanços em Inteligência Artificial e Visão Computacional têm possibilitado o desenvolvimento de tecnologias assistivas capazes de realizar detecção de objetos em tempo real. Arquiteturas da família YOLO têm sido empregadas nesse contexto devido à relação entre precisão e velocidade de inferência, característica relevante para aplicações que demandam resposta imediata. Revisões da literatura demonstram a crescente utilização dessas técnicas em sistemas destinados à assistência de pessoas com deficiência visual [3,4].

Diferentes abordagens têm explorado modelos de detecção de objetos para navegação assistiva. [5] empregaram YOLOv7 na identificação de objetos em diferentes cenários, enquanto compararam arquiteturas de detecção aplicadas à identificação de obstáculos. [7] demonstraram a viabilidade da execução de modelos de detecção em dispositivos móveis, e [8] combinaram detecção de objetos e estimativa de profundidade para interpretação espacial do ambiente. Soluções vestíveis também têm sido investigadas, como o sistema de [9], que associa visão computacional à geração de alertas sonoros. Adicionalmente, [10] demonstraram a importância da utilização de conjuntos de dados específicos do domínio para melhorar o desempenho dos modelos em cenários reais.

Apesar desses avanços, aplicações assistivas embarcadas apresentam desafios relacionados tanto à capacidade de detecção quanto ao custo computacional e à generalização dos modelos. Arquiteturas com maior complexidade podem apresentar desempenho preditivo elevado, porém sua utilização em plataformas com recursos limitados pode comprometer a latência e a taxa de processamento necessárias para aplicações em tempo real. Além disso, o desempenho obtido durante o treinamento pode não se manter diante de variações nos objetos e nos ambientes encontrados durante a utilização do sistema. Dessa forma, torna-se relevante não apenas utilizar dados específicos do domínio, mas também avaliar o comportamento dos modelos em cenários distintos daqueles representados durante a construção do conjunto de dados.

Diante desse cenário, este trabalho propõe o desenvolvimento e a avaliação de um protótipo de sistema assistivo vestível, baseado em visão computacional embarcada, para identificação de objetos potencialmente perigosos em corredores escolares. Para isso, foi construído um conjunto de dados específico contendo objetos associados ao contexto de aplicação e foram avaliadas diferentes arquiteturas de visão computacional, considerando métricas de desempenho preditivo e complexidade computacional. A partir dessa análise, os modelos com melhor desempenho foram selecionados para avaliação experimental em corredores escolares, considerando tanto um ambiente representado durante a construção do conjunto de dados quanto um ambiente não observado nessa etapa.

Portanto, a hipótese investigada neste trabalho é que modelos treinados com dados específicos do ambiente escolar podem identificar objetos potencialmente perigosos mesmo quando submetidos a variações no cenário de aplicação, mantendo características computacionais compatíveis com sua utilização em uma plataforma embarcada. Dessa forma, o

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

trabalho busca avaliar tanto a capacidade de identificação dos objetos e o comportamento dos modelos diante de mudanças no ambiente quanto sua aplicabilidade em um dispositivo vestível de prototipação rápida.

II. METODOLOGIA

Este trabalho caracteriza-se como uma pesquisa aplicada e experimental, conduzida por meio do desenvolvimento e da avaliação de um protótipo de visão computacional embarcada. O procedimento metodológico foi organizado em cinco etapas: construção e preparação do conjunto de dados, treinamento das arquiteturas, avaliação e seleção dos modelos, desenvolvimento do protótipo embarcado e avaliação experimental nos ambientes escolares.

A. Construção e preparação do conjunto de dados

Foram definidas cinco classes de objetos presentes em corredores escolares: cleaning cart (carrinho de limpeza), fire extinguisher (extintor), safety cone (cone de sinalização), water fountain (bebedouro) e trash can (lixeira). As imagens correspondentes a essas classes foram organizadas na plataforma Roboflow, na qual foi realizado o processo de anotação dos objetos. Para as tarefas de detecção, as regiões correspondentes aos objetos foram delimitadas por bounding boxes e associadas às respectivas classes. Para os experimentos envolvendo segmentação, o conjunto de dados foi preparado no formato correspondente às máscaras de segmentação.

B. Treinamento das arquiteturas

O treinamento dos modelos foi realizado no ambiente Google Colab. Foram incluídas no protocolo experimental as arquiteturas YOLO11, YOLO26, RT-DETR, MobileNetV3, SegFormer e U-Net, contemplando abordagens de detecção de objetos e segmentação semântica. Os modelos foram treinados utilizando o conjunto de dados preparado para as respectivas tarefas, sendo armazenados os pesos e os registros das métricas produzidas durante o treinamento e a validação para posterior análise.

Para o treinamento do YOLO11, o conjunto de dados foi dividido em 82% para treinamento, 1% para validação e 17% para teste. Para o SegFormer, foram utilizados 70% para treinamento, 20% para validação e 10% para teste. As divisões empregadas nas demais arquiteturas não foram consideradas nesta descrição por não estarem disponíveis nos registros experimentais utilizados na elaboração deste trabalho.

C. Avaliação e seleção dos modelos

A avaliação das arquiteturas foi realizada considerando tanto o desempenho preditivo quanto parâmetros associados ao custo computacional. Para os modelos de detecção foram consideradas as métricas mean Average Precision com IoU de 0,50 (mAP@50), precisão, recall e F1-score. Para os modelos de segmentação foi adotado o mean Intersection over Union (mIoU). O F1-score foi calculado a partir dos valores de precisão e recall.

Também foram considerados GFLOPs, tamanho do modelo, latência de processamento e taxa de quadros por segundo (FPS). A latência por imagem foi determinada considerando os tempos de pré-processamento, inferência e pós-processamento, enquanto o FPS foi obtido a partir do tempo total de processamento de cada quadro.

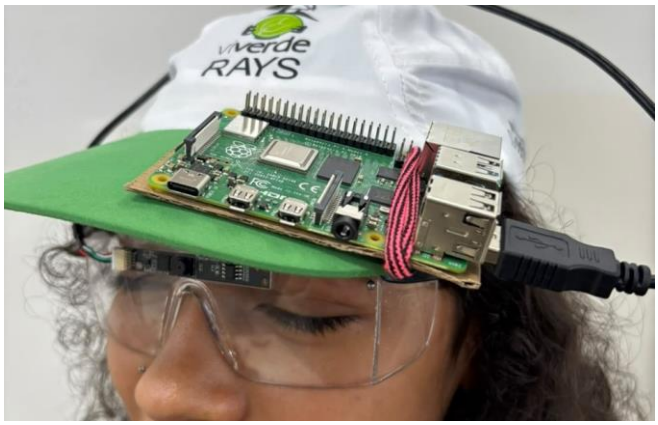
A partir dessa avaliação preliminar, YOLO11 e YOLO26 foram selecionados para a etapa seguinte dos experimentos por apresentarem os melhores resultados entre as arquiteturas avaliadas. Os dois modelos foram então submetidos aos testes de detecção nos ambientes escolares, permitindo comparar seu comportamento diante das condições consideradas na aplicação proposta.

D. Desenvolvimento do protótipo embarcado

Para o desenvolvimento do protótipo embarcado foi utilizada uma plataforma Raspberry Pi 4 Model B+ executando Raspberry Pi OS. O sistema foi constituído por uma câmera conectada à unidade de processamento para aquisição das imagens, uma interface de áudio para emissão dos alertas e uma fonte portátil de alimentação (Figura 1). A aplicação foi implementada em Python, utilizando OpenCV para aquisição e processamento dos quadros provenientes da câmera e a biblioteca Ultralytics para execução do modelo de detecção.

O processamento foi organizado em um fluxo sequencial composto pela captura do quadro da câmera, pré-processamento da imagem, inferência pelo modelo e processamento das detecções. Para cada objeto detectado foram obtidos a classe atribuída, as coordenadas da bounding box e o nível de confiança da predição. Essas informações foram utilizadas pela aplicação como entrada para o mecanismo responsável pela geração do alerta sonoro.

Fig.1 - Protótipo desenvolvido. Fonte: autores



E. Avaliação experimental nos ambientes escolares

A avaliação experimental dos modelos YOLO11 e YOLO26 foi realizada considerando dois cenários. O primeiro correspondeu ao corredor utilizado durante a aquisição das imagens que compuseram o conjunto de dados, denominado ambiente conhecido. O segundo correspondeu a outro corredor da instituição, cujas características e objetos não haviam sido utilizados durante a coleta das imagens de treinamento, denominado ambiente não observado. A utilização dos dois cenários teve como finalidade observar o comportamento dos modelos tanto em condições semelhantes às representadas no conjunto de dados quanto diante de uma mudança de ambiente.

Nos dois cenários foram avaliadas as cinco classes definidas para o conjunto de dados. Durante os experimentos, o usuário transitou em postura ereta portando o protótipo, enquanto os objetos eram apresentados à câmera em diferentes

condições de distância. Para cada detecção foram registrados a classe identificada e o nível de confiança atribuído pelo modelo. Também foram observadas as situações em que uma das classes avaliadas não foi reconhecida.

A variação da distância entre a câmera e os objetos foi considerada na análise do comportamento das detecções, permitindo observar as alterações produzidas nos níveis de confiança dos modelos. Os resultados obtidos nos dois ambientes foram posteriormente comparados quanto às classes reconhecidas, aos níveis de confiança das detecções e ao comportamento dos modelos diante da mudança de cenário.

III. Resultados

A. *Treinamento e avaliação das arquiteturas*

Inicialmente, foram avaliadas seis arquiteturas: YOLO11, YOLO26, RT-DETR, MobileNetV3, SegFormer e U-Net, considerando precisão, velocidade e viabilidade em hardware limitado, como o Raspberry Pi. O SegFormer e a U-Net foram descartados por serem voltados à segmentação semântica, enquanto o projeto busca a identificação e localização de objetos. O MobileNetV3 apresentou desempenho inferior nos testes, apesar de ser adequado a dispositivos de menor capacidade. Já o RT-DETR apresentou boa precisão, mas maior complexidade computacional, dificultando sua aplicação no protótipo.

Assim, foram selecionados o YOLO11 e o YOLO26. O YOLO11 se destaca pelo equilíbrio entre precisão, velocidade e eficiência computacional, enquanto o YOLO26 permite comparar diferentes versões da arquitetura YOLO. Os dois modelos foram avaliados para determinar o mais adequado à detecção de objetos em corredores escolares, considerando também as limitações do hardware utilizado no protótipo.

B. *Caracterização dos cenários de avaliação*

Após a etapa de treinamento e avaliação das arquiteturas, os modelos YOLO11 e YOLO26 foram selecionados para os experimentos de detecção nos corredores escolares. A avaliação considerou as cinco classes definidas para o conjunto de dados: *cleaning cart* (carrinho de limpeza), *fire extinguisher* (extintor), *safety cone* (cone de sinalização), *water fountain* (bebedouro) e *trash can* (lixeira).

Os experimentos foram conduzidos em dois cenários. O primeiro correspondeu ao corredor utilizado durante a etapa de aquisição das imagens que compuseram o conjunto de dados, sendo denominado neste trabalho ambiente conhecido (Figura 1). O segundo correspondeu a outro corredor da instituição, cujas características e objetos não haviam sido utilizados durante a coleta das imagens de treinamento, sendo denominado ambiente não observado (Figura 2). Essa configuração permitiu avaliar o comportamento dos modelos tanto em condições semelhantes às representadas no conjunto de dados quanto diante de uma mudança de ambiente.

Durante os experimentos, foram consideradas as detecções realizadas com o usuário transitando em postura ereta e em condições adequadas de proximidade dos objetos avaliados. Para cada detecção, foram registrados a classe identificada e o nível de confiança atribuído pelo modelo. Ambos os corredores foram utilizados durante a etapa de aquisição das imagens que compuseram o conjunto de dados.

Fig. 1 – Corredor original. Fonte: autores.

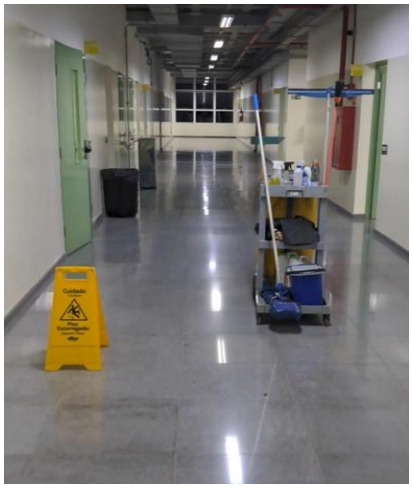
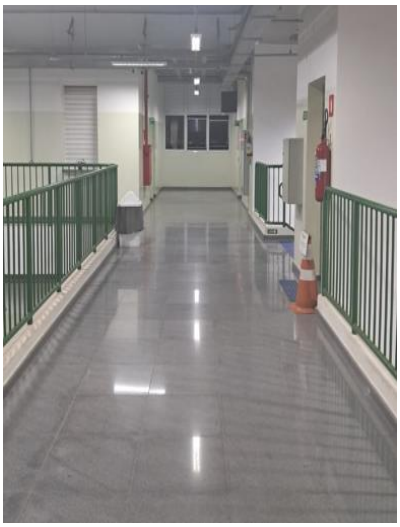


Fig. 2 – Ambiente não observado. Fonte: autores.



C. *Desempenho dos modelos durante o treinamento*

A evolução das métricas de treinamento dos modelos selecionados é apresentada nas Figuras 3 e 4. Tanto o YOLO11 quanto o YOLO26 apresentaram crescimento acentuado do mAP nas primeiras épocas, atingindo posteriormente valores próximos de 100%. Esse comportamento indica que ambos os modelos conseguiram aprender as características das classes presentes no conjunto de dados utilizado no treinamento.

Para o YOLO26, o mAP@50-95 apresentou crescimento progressivo e posterior estabilização entre aproximadamente 70% e 75%. No YOLO11, essa métrica estabilizou-se em valores entre aproximadamente 65% e 70%. Considerando essa métrica, portanto, o YOLO26 apresentou desempenho ligeiramente superior durante o treinamento.

A evolução da class loss também apresentou comportamento semelhante nos dois modelos. Observou-se uma redução acentuada nas primeiras épocas, seguida de estabilização em valores baixos ao longo do restante do treinamento. Em conjunto com a evolução do mAP, esse comportamento indica a convergência dos modelos durante o

processo de treinamento. Entretanto, os resultados obtidos nessa etapa devem ser analisados em conjunto com os experimentos realizados nos corredores, uma vez que o desempenho sobre o conjunto de dados não necessariamente representa o comportamento do modelo diante de imagens obtidas em outros ambientes.

Fig. 3 – Desempenho do Yolo26. Fonte: autores.

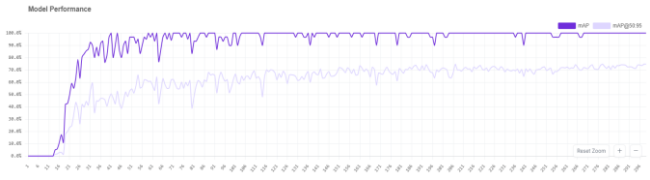
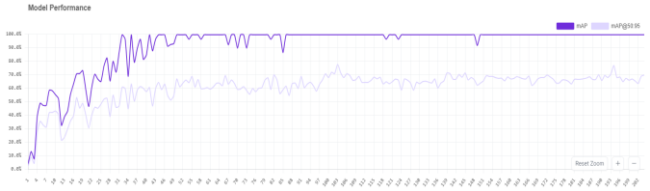


Fig. 4 – Desempenho do Yolo11. Fonte: autores.



D. Desempenho da detecção nos ambientes avaliados

A Tabela 1 apresenta os níveis de confiança obtidos pelos modelos YOLO11 e YOLO26 para as cinco classes nos ambientes conhecido e não observado.

Tabela 1 - Níveis de confiança das detecções obtidas pelos modelos YOLO11 e YOLO26 nos dois ambientes avaliados

Objeto	**YOLO26 – Corredor original**	**YOLO11 – Corredor original**	**YOLO26 – Corredor desconhecido**	**YOLO11 – Corredor desconhecido**
Cone de segurança	94%	51%	67%	87%
Extintor de incêndio	88%	83%	66%	67%
Carrinho de limpeza	86%	74%	77%	72%
Lixeira	Não reconhecida	62%	Não reconhecida	Não reconhecida
Bebedouro	Não reconhecido	62%	Não reconhecido	Não reconhecido

No ambiente conhecido, o YOLO26 detectou três das cinco classes avaliadas. O cone de sinalização apresentou confiança de 94%, seguido pelo extintor, com 88%, e pelo carrinho de limpeza, com 86%. A lixeira e o bebedouro não foram reconhecidos nesse cenário. O YOLO11, por sua vez, detectou as cinco classes, apresentando 83% de confiança para o extintor, 74% para o carrinho de limpeza, 62% para a lixeira, 62% para o bebedouro e 51% para o cone de sinalização.

Os resultados mostram, portanto, comportamentos distintos entre os modelos no ambiente conhecido. Entre as classes reconhecidas por ambos, o YOLO26 apresentou níveis de confiança superiores para cone, extintor e carrinho de limpeza. Entretanto, somente o YOLO11 foi capaz de detectar todas as cinco classes avaliadas nesse ambiente.

No ambiente não observado durante a composição do conjunto de dados, ambos os modelos detectaram três das cinco classes. O YOLO26 apresentou confiança de 77% para o carrinho de limpeza, 67% para o cone de sinalização e 66% para o extintor. Para o YOLO11, foram obtidos 87% para o cone de sinalização, 72% para o carrinho de limpeza e 67% para o extintor. Lixeira e bebedouro não foram detectados por nenhum dos modelos nesse cenário.

Também foram observadas variações nos níveis de confiança em função da distância entre a câmera e os objetos. Nos experimentos com o YOLO26, foram registradas variações de até 25 pontos percentuais no ambiente conhecido e de até 15 pontos percentuais no ambiente não observado. Para o YOLO11, as variações ficaram entre aproximadamente 15 e 20 pontos percentuais. Esses resultados evidenciam que a posição relativa entre câmera e objeto constitui uma condição relevante para o comportamento das detecções.

E. Comparação entre YOLO11 e YOLO26

A comparação dos resultados evidencia que os modelos apresentaram características distintas. No ambiente conhecido, o YOLO26 produziu os maiores níveis de confiança para as três classes detectadas por ambos os modelos. A diferença foi particularmente expressiva para o cone de sinalização, cuja confiança foi de 94% no YOLO26 e 51% no YOLO11. Para o extintor, foram obtidos 88% e 83%, respectivamente, enquanto para o carrinho de limpeza os valores foram de 86% e 74%.

Entretanto, níveis de confiança mais elevados nas classes detectadas não implicaram maior cobertura das classes avaliadas. Enquanto o YOLO26 reconheceu três das cinco classes no ambiente conhecido, o YOLO11 detectou as cinco. Esse resultado é relevante para a aplicação proposta, uma vez que a ausência de detecção de um objeto potencialmente perigoso pode ser tão importante quanto o nível de confiança atribuído às detecções realizadas.

A mudança para o ambiente não observado modificou esse comportamento. Nesse cenário, ambos os modelos reconheceram três classes. O YOLO11 apresentou maior confiança para o cone de sinalização (87% contra 67%) e valores próximos aos do YOLO26 para o extintor (67% contra 66%). Para o carrinho de limpeza, o YOLO26 apresentou confiança de 77%, enquanto o YOLO11 atingiu 72%.

Destaca-se ainda que lixeira e bebedouro não foram reconhecidos por nenhum dos modelos no ambiente não observado, apesar de terem sido detectados pelo YOLO11 no ambiente conhecido. As diferenças visuais entre os objetos presentes nos dois ambientes constituem uma possível explicação para esse comportamento; contudo, os experimentos realizados não permitem estabelecer isoladamente a causa dessas falhas de detecção. Os resultados indicam, portanto, uma redução da capacidade de reconhecimento de determinadas classes quando os modelos são submetidos a condições diferentes daquelas representadas no conjunto de dados.

De forma geral, o YOLO26 apresentou maiores níveis de confiança para algumas classes, especialmente no ambiente conhecido, enquanto o YOLO11 apresentou maior cobertura das classes nesse mesmo cenário. Os resultados no ambiente não observado mostram ainda que a análise baseada exclusivamente nas métricas obtidas durante o treinamento não é suficiente para caracterizar o comportamento dos modelos em condições distintas das utilizadas na construção do conjunto de dados.

F. Implicações para o protótipo embarcado

Os resultados obtidos apresentam implicações diretas para a utilização dos modelos no protótipo assistivo. Em uma aplicação destinada à identificação de objetos potencialmente perigosos, não apenas o nível de confiança das detecções deve ser considerado, mas também a capacidade do sistema de reconhecer diferentes classes diante de variações do ambiente e da distância entre a câmera e os objetos.

Nesse sentido, embora o YOLO26 tenha apresentado valores superiores de mAP@50-95 durante o treinamento e maiores níveis de confiança para determinadas classes, o YOLO11 apresentou a vantagem de reconhecer todas as cinco classes no ambiente conhecido. Por outro lado, a ausência de detecção da lixeira e do bebedouro por ambos os modelos no ambiente não observado evidencia uma limitação relevante para a aplicação proposta e indica a necessidade de ampliar a diversidade de imagens utilizadas no treinamento, particularmente quanto às variações visuais dos objetos e dos ambientes nos quais o sistema deverá operar.

Os experimentos também demonstraram que a distância entre a câmera e os objetos influencia os níveis de confiança das detecções, aspecto particularmente relevante em um dispositivo vestível, no qual a posição da câmera varia continuamente durante o deslocamento do usuário. Dessa forma, os resultados obtidos indicam o potencial da utilização dos modelos para a identificação das classes consideradas, mas também evidenciam limitações de generalização que devem ser consideradas na evolução do protótipo e na ampliação do conjunto de dados.

IV. CONCLUSÕES

Este trabalho apresentou o desenvolvimento e a avaliação de uma solução de visão computacional voltada à identificação de objetos potencialmente perigosos em corredores escolares, visando sua aplicação em um protótipo assistivo vestível. A partir da construção de um conjunto de dados específico do domínio e da avaliação de diferentes arquiteturas, os modelos YOLO11 e YOLO26 foram selecionados para os experimentos conduzidos em um ambiente representado durante a construção do conjunto de dados e em um ambiente não observado nessa etapa.

Os resultados demonstraram comportamentos distintos entre os modelos. O YOLO26 apresentou valores superiores de mAP@50-95 durante o treinamento e maiores níveis de confiança para determinadas classes no ambiente conhecido. O YOLO11, entretanto, apresentou maior cobertura nesse cenário, sendo capaz de detectar as cinco classes avaliadas. No ambiente não observado, ambos os modelos detectaram três das cinco classes, não reconhecendo lixeira e bebedouro. Também foram observadas variações nos níveis de confiança em função da distância entre a câmera e os objetos. Esses resultados mostram que métricas obtidas durante o treinamento, isoladamente, não são suficientes para caracterizar o comportamento dos modelos nas condições de aplicação.

Dessa forma, a hipótese proposta foi parcialmente sustentada. Os experimentos demonstraram o potencial de modelos treinados com dados específicos do ambiente escolar para a identificação dos objetos considerados, inclusive diante de mudanças no cenário de aplicação. Entretanto, as falhas de detecção observadas no ambiente não representado durante a construção do conjunto de dados evidenciam limitações de generalização que ainda precisam ser superadas. Além disso, embora o protótipo tenha sido desenvolvido sobre uma plataforma embarcada, os resultados apresentados não permitem concluir de forma definitiva sobre seu desempenho em tempo real, uma vez que a avaliação experimental não contemplou uma análise sistemática de latência e FPS durante a execução no Raspberry Pi.

Como continuidade do trabalho, propõe-se ampliar o conjunto de dados, incorporando maior diversidade de ambientes, objetos, perspectivas e distâncias, bem como realizar uma avaliação sistemática do desempenho computacional dos modelos diretamente na plataforma embarcada. Também se recomenda ampliar os experimentos com usuários e em diferentes condições de circulação, permitindo avaliar não apenas o desempenho dos modelos de visão computacional, mas a efetividade do sistema assistivo em condições mais próximas de sua utilização real.

REFERENCES

[1] W. Pickett et al., "Multiple risk behavior and injury: an international analysis of young people," Arch. Pediatr. Adolesc. Med., vol. 156, no. 8, pp. 786–793, 2002.

[2] S. Stadtmüller et al., "Approaching the causes of unintentional injuries in the school environment: a panel analysis of survey data from Germany," J. Sch. Health, vol. 92, no. 2, pp. 148–156, 2022, doi: 10.1111/josh.13112.

[3] M. M. Valipoor and A. De Antonio, "Recent trends in computer vision-driven scene understanding for VI/blind users: a systematic mapping," Univers. Access Inf. Soc., vol. 22, no. 3, pp. 983–1005, 2023, doi: 10.1007/s10209-022-00868-w.

[4] D. Klann, A. M. R. Fernandes, E. A. Silva, and W. D. Parreira, "Explorando algoritmos de visão computacional em tecnologias assistivas: uma revisão sistemática da literatura," J. Health Inform., 2024.

[5] O. K. T. Alsultan and M. T. Mohammad, "A deep learning-based assistive system for the visually impaired using YOLO-V7," Rev. Intell. Artif., vol. 37, no. 4, pp. 901–906, 2023, doi: 10.18280/ria.370409.

[6] R. Litoriya et al., "Implementing visual assistant using YOLO and SSD for visually-impaired persons," J. Autom. Mob. Robot. Intell. Syst., vol. 17, no. 4, pp. 79–87, 2023.

[7] M. T. F. Santiago, M. V. B. Faria, M. V. P. Malvar, and L. O. Nascimento, "Object identification for visually impaired," J. Bioeng. Technol. Health, vol. 6, no. 4, pp. 296–300, 2023.

[8] L. Gassenn et al., "Aplicação de modelos de aprendizado profundo na estimativa de relações espaciais dos objetos para auxiliar pessoas com deficiência visual," in Proc. Simp. Bras. Comput. Aplic. Saúde (SBCAS), 2024.

[9] G. L. Silva and L. G. P. Silva, "Óculos de assistência na locomoção para deficientes visuais," Rev. GeTeC, vol. 21, pp. 139–158, 2025.

[10] X. Li et al., "A dataset for the visually impaired walk on the road," Displays, vol. 79, Art. no. 102486, 2023.